Actividad de clase: Regresión, Gradient Descent y Regularización

Sin código!

Durante toda la actividad trabajaremos con las siguientes observaciones:

x	y
0	1
1	3
2	4
3	7
4	8
5	12

Parte 1: primer modelo

Nuestro objetivo es construir un modelo que permita predecir y a partir de x.

Consideremos el modelo $\hat{y} = 1 + wx$. Comenzaremos utilizando $w = 1$

Predicciones y errores: complete la siguiente tabla

x	y	ŷ	y – ŷ	|y – ŷ|	(y – ŷ)²
0	1	1	0	0	0
1	3	2	1	1	1
2	4	3	1	1	1
3	7	4	3	3	9
4	8	5	3	3	9
5	12	6	6	6	36

Calcule:

$$MAE = \frac{1}{N}\sum_i |y_i - \hat{y}_i|$$

$$MSE = \frac{1}{N}\sum_i (y_i - \hat{y}_i)^2$$

MAE = 14/6 = 2.44
MSE = 56/6 = 9.33

Preguntas:
• ¿El modelo tiende a sobreestimar o subestimar los valores observados?

Este modelo tiende a subestimar los valores observados.

• Mirando los residuos, ¿qué cambio harían en w para mejorar el modelo?

Se debería aumentar w para disminuir los residuos.

• ¿Cómo podríamos decidir sistemáticamente cuánto modificar w?

Hay que ver como cambia el error al aumentar w. Es decir la del costo respecto a w.

Parte 2. Mejorando el modelo

En lugar de elegir w al azar, exploremos cómo cambia el error.
Calcule el MSE para los siguientes valores de w:

$$w = 1.0, 1.5, 2.0, 2.5$$

Utilice $\hat{y} = 1 + wx$. Complete la tabla

w	MSE
1.0	9.33
1.5	2.63
2.0	0.50
2.5	2.96

Preguntas:
• ¿Al aumentar w, el MSE siempre disminuye?

No necesariamente. Se puede ver que un 2 de 2.5 tiene mayor MSE que 2.0.

• Si actualmente estamos en $w = 1$, ¿en qué dirección deberíamos movernos?

Se debe aumentar w

• Si estuviéramos en $w = 2.5$, ¿en qué dirección deberíamos movernos?

Se debe disminuir w

• A partir de los resultados de la tabla, ¿dónde parece encontrarse aproximadamente el mínimo del MSE?

Este está cercano a 2 ya que tiene el mejor MSE.

Parte 3. Una iteración de Gradient Descent

Hasta ahora hemos probado diferentes valores de w. Queremos ahora encontrar una manera sistemática de decidir cómo modificarlo.

Para nuestro modelo $\hat{y}_i = 1 + wx_i$, y utilizando MSE como función de costo

$$J(w) = \frac{1}{N}\sum_i (y_i - \hat{y}_i)^2$$

Encuentre el gradiente de la función de costo respecto de w. Calcule inicialmente para $w = 1$.

El gradiente de J respeto a w es:

$-\ (2/N)\Sigma\, x_i(y_i - \hat{y}_i)$

Evaluando en 1 se tiene:

-(2/6)* (0 + 1 + 2 + 9 + 12 + 30) = -(2/6) * 54 = -18

Según el signo del gradiente, ¿deberíamos aumentar o disminuir w?

El gradiente es negativo, así que J baja si w sube por lo que hay que aumentar w.

Gradient Descent actualiza el parámetro mediante:

$$w_{nuevo} = w_{anterior} - \eta\frac{\partial J}{\partial w}$$

Utilicen un learning rate de $\eta = 0.05$.

• Calcule el nuevo valor de w.

w = 1 – 0.05 * (-18) = 1.9

• Calcule nuevamente las seis predicciones.

x	y	$\hat{y}$	$y-\hat{y}$	$(y-\hat{y})^2$
0	1	1.0	0	0
1	3	2.9	0.1	0.01
2	4	4.8	-0.8	0.64
3	7	6.7	0.3	0.09
4	8	8.6	-0.6	0.36
5	12	10.5	1.5	2.25

• Calcule el nuevo MSE.

(0.01+0.64+0.09+0.36+2.25)/6 = 3.35/6 = 0.558

• Compare el nuevo MSE con el obtenido inicialmente.

Antes se tenía un MSE de 9.33 mientras que ahora es 9.558 el cual es mucho mas pequeño.

Preguntas:
• ¿Mejoró el modelo?

Si mejoro. El MSE bajó más de 16 veces en una sola iteración.

• ¿Qué cree que ocurriría si el learning rate fuese extremadamente pequeño?

El algoritmo avanzaría en la dirección correcta, pero al tener un learning rate muy pequeño se demoraría muchas iteraciones en converger.

• ¿Qué cree que ocurriría si fuese demasiado grande?

El algoritmo se pasaría del mínimo y podría oscilar alrededor del valor mínimo sin llegar nunca.

• ¿Más iteraciones solucionarían necesariamente cualquiera de estos problemas?

Con un learning rate chico más iteraciones lo arreglan pero con un learning rate mas grande, añadir iteraciones solo empeora el algoritmo.

Parte 4. Métricas y errores

Consideremos ahora el modelo $\hat{y} = 1 + 2x$ y volvamos a los datos originales.
Calcule su MAE y MSE.
Suponga ahora que la última observación hubiese sido $(x, y) = (5, 20)$ en lugar de $(x, y) = (5, 12)$

Antes de calcular: ¿Espera que el cambio afecte más al MAE o al MSE? ¿Por qué?

El MSE se espera que cambie ya que este usa valores cuadrados, los cuales se ven más elevados.

Calcule nuevamente ambas métricas y complete la tabla

Métrica	Datos originales	Con y=20
MAE	0.50	11/6 = 1.83
MSE	0.50	83/6 = 13.83

Preguntas:

- ¿Cuál de las dos métricas reaccionó más al punto extremo? ¿Por qué ocurre esto?

El MSE aumentó mucho. aproximadamente 28 veces. El MAE subió solo unas 3.7 veces. Esto es debido a que el cuadrado en el MSE hace que una contribución sea mucho mayor e importante.

- Si $y = 20$ fuese producto de un problema instrumental, ¿qué métrica preferirían para evaluar el modelo?

Aquí convendría el MAE ya que este toma menos en cuenta los outliers. En cambio el MSE les da mucho más peso.

- ¿Cambiaría su respuesta si $y = 20$ fuese una observación real y científicamente interesante?

Si ya que el MSE resalta este valor el cual es importante. El MAE podria esconderlo.

Parte 5. Qué significa un mejor modelo?

Volvamos nuevamente a los seis datos originales. Tenemos nuestro modelo lineal:

$$Modelo\ A: \hat{y} = 1 + 2x$$

Para estos datos, $MSE_A = 0.50$

Otro grupo propone utilizar un modelo mucho más flexible, un polinomio de grado 5:

$$Modelo\ B: \hat{y} = 1 + 8.45x - 11.875x^2 + \frac{83}{12}x^3 - 1.625x^4 + \frac{2}{15}x^5$$

Este modelo pasa exactamente por las seis observaciones:

$$MSE_B = 0$$

¿Cuál de los dos modelos elegiría a partir de esta información? Justifique.

Solo a partir de esta información elegiría el modelo B ya que tiene un MSE = 0. No hay error para los 6 datos.

Llegan nuevas observaciones. Después de construir los modelos obtenemos dos nuevas mediciones:

x	y
6	13
7	15

El Modelo A predice:

x	Valor real	Predicción
6	13	13
7	15	15

Mientras que el Modelo B predice aproximadamente:

x	Valor real	Predicción
6	13	49
7	15	190

Preguntas:

- ¿Cuál modelo tiene menor error sobre los datos utilizados para construirlo?

El modelo A predice ambos valores de manera perfecta y sin errores. Mientras que el modelo B tiene unas predicciones muy alejadas de la realidad con errores muy grandes. ($((49 - 13)^2 + (190 - 15)^2)/2 =$ 15 960.)

- ¿Cuál funciona mejor sobre las nuevas observaciones?

Con las nuevas observaciones funciona mejor el modelo A

- ¿Qué ocurrió con el Modelo B?

El modelo B, al ser más complejo, solo estaba adaptado a los 6 valores iniciales. Estaba aprendiendo los de memoria. Hizo overfitting.

- ¿Por qué el MSE calculado sobre los datos originales (de entrenamiento) no fue suficiente para detectar este problema?

Ya que al estar sobre ajustado a estos datos, el modelo B tiene una precisión perfecta con estos mismos. El problema fue entregarle datos que no conocía.

- ¿Significa esto que los modelos más complejos son siempre peores?

No necesariamente. Depende de la situación y de los datos. Cuando hay situaciones complejas, un modelo más complejo puede ser útil. Y a veces un modelo muy simple puede ser demasiado general y sub ajustar lo que está pasando. Se debe ser cuidadoso y encontrar un punto en el que no haya sobre ajuste ni sub ajuste.